Ejercicio 8. Cambio de esquema: detección de anomalías con aprendizaje automático

Rivera Munguia Ameyalli · Proyecto asignado: Obras Públicas Temascaltepec (PublicMunicipalWorks_DWH)

Cambio al esquema

Tabla	Tipo de cambio	Columnas clave	Restricciones
`warehouse.modelo_ml`	Nueva	modelo_key, nombre, version, algoritmo, hiperparametros (JSONB), variables_entrada, fecha_entrenamiento	PK; UNIQUE (nombre, version)
`warehouse.prediccion_anomalia`	Nueva	tiempo_key + obra_key (hecho calificado), modelo_key, puntaje_anomalia, es_anomalia, generado_en	FK compuesta a `fact_obra_mensual` ON DELETE CASCADE; FK a `modelo_ml` ON DELETE RESTRICT; CHECK puntaje entre 0 y 1; UNIQUE (hecho, modelo)

Resultado de la consulta (`consulta-usuario.sql`) sobre la copia de la base: la OBRA-0003 tiene un puntaje de 0.917 y queda marcada como anómala, con 80 % del presupuesto pagado y solo 25 % de avance físico. La vista original de reglas fijas **no** la marca, porque su criterio exige más de 80 % pagado.

Nota

Regla aplicada. `modelo_ml` es una entidad fuerte (regla 1): cada versión entrenada del modelo existe por sí misma. `prediccion_anomalia` resulta de dos relaciones uno a muchos (regla 4): un hecho mensual puede tener varias predicciones y una versión del modelo genera muchas. Por eso la tabla lleva la clave de ambos lados como claves foráneas NOT NULL. La referencia al hecho es compuesta (`tiempo_key`, `obra_key`) porque esa es la clave primaria de `fact_obra_mensual`.

Por qué esta estrategia. Se eligió una tabla aparte en lugar de agregar columnas a `fact_obra_mensual` porque el mismo mes de una obra puede evaluarse con varias versiones del modelo. Con columnas, cada reentrenamiento borraría el resultado anterior y no se podrían comparar versiones. El UNIQUE (hecho, modelo) impide evaluar dos veces lo mismo con la misma versión. `ON DELETE RESTRICT` sobre el modelo evita borrar una versión que ya produjo resultados, para conservar la trazabilidad.

Datos existentes. El cambio solo crea tablas nuevas: no modifica columnas ni filas de `fact_obra_mensual` ni de las dimensiones, y la vista `v_anomalias_deteccion` sigue funcionando igual. Los snapshots mensuales que ya existen quedan sin predicción hasta que el modelo se ejecute sobre ellos; no hace falta un valor por omisión ni recalcular nada.

Tipos de dato. El puntaje de Isolation Forest, normalizado entre 0 y 1, se guarda en `NUMERIC(6,5)` y no en `REAL`, porque un tipo exacto permite comparar contra el umbral (0.70) sin errores de redondeo. El veredicto es `BOOLEAN` para filtrar e indexar directo. La marca de tiempo es `TIMESTAMPTZ`, como el resto del almacén. Los hiperparámetros van en `JSONB` porque cambian según el algoritmo.