

EJERCICIO 4. ESTADO DEL ARTE: TRES ARTÍCULOS CIENTÍFICOS

Artículo: “[Effectively Learning Spatial Indices](#)” (Aprender de forma eficaz los índices espaciales)

Autores: Jianzhong Qi, Guanli Liu, Christian S. Jensen y Lars Kulik.

Año: 2020

DOI: <https://doi.org/10.14778/3407790.3407829>

Problema que aborda:

El artículo aborda el problema de cómo realizar búsquedas de manera más rápida en bases de datos que contienen grandes cantidades de datos espaciales, como ubicaciones o coordenadas. Los autores señalan que los índices tradicionales pueden requerir recorrer muchos nodos durante una consulta, lo que puede disminuir el rendimiento cuando se manejan grandes volúmenes de información.

Método o propuesta de los autores

Los autores proponen utilizar aprendizaje automático para crear índices espaciales, en lugar de depender únicamente de estructuras tradicionales como los R-trees. Para lograrlo, organizan los puntos mediante un sistema basado en *rank space* y utilizan una estrategia de partición recursiva, donde una red neuronal aprende a identificar en qué parte de la estructura se encuentra cada dato. También desarrollan métodos para realizar consultas de puntos, ventanas y vecinos más cercanos (kNN).

Resultado principal

Los experimentos realizados con datos reales y sintéticos de más de 100 millones de puntos mostraron que el índice propuesto puede procesar consultas de manera considerablemente más rápida que los R-trees y que otro índice basado en aprendizaje automático. Los autores reportan que, en sus experimentos, algunas consultas fueron más de diez veces más rápidas que utilizando estas alternativas.

Relación con la Unidad Temática I

Tema relacionado: [1.3.3 Módulos componentes de un SGBD](#).

Considero que se relaciona principalmente con este tema porque los índices forman parte de los mecanismos que utiliza un sistema de bases de datos para acceder a la información de manera eficiente. El artículo muestra cómo uno de estos mecanismos puede incorporar aprendizaje automático para mejorar el acceso y procesamiento de los datos.

También se relaciona con [1.1.1 Fundamentos de Bases de Datos](#), porque parte de un problema fundamental de las bases de datos: organizar la información y encontrarla de manera eficiente cuando se realizan consultas.

¿Qué me aporta para mi proyecto del curso? Este artículo me ayuda a entender que una base de datos no solamente sirve para almacenar información, sino que también es importante considerar cómo se consulta y procesa esa información de manera eficiente. Para mi proyecto sobre el impacto físico de actividades digitales, podría ser útil si se maneja una gran cantidad de registros sobre:

- Productos con mayor consumo de agua.
- Productos con mayores emisiones.
- Productos reciclables.
- Impacto promedio por categoría.
- Impacto por país.
- Materiales utilizados con mayor frecuencia.

Además, me permite relacionar mi proyecto con la Inteligencia Artificial, ya que muestra un ejemplo real de cómo el aprendizaje automático puede utilizarse para mejorar el funcionamiento de una base de datos y no solamente para analizar los datos después de almacenarlos.

Qi, J., Liu, G., Jensen, C. S., & Kulik, L. (2020).
Effectively learning spatial indices. *Proceedings Of
The VLDB Endowment*, 13(12), 2341-2354. <https://doi.org/10.14778/3407790.3407829>

Artículo: “[Modeling Shifting Workloads for Learned Database Systems](#)”
(Modelización de cargas de trabajo variables para sistemas de bases de datos con capacidad de aprendizaje)

Autores: Peizhi Wu, Zachary G. Ives

Año: 2024

DOI: <https://doi.org/10.14778/3407790.3407829>

Problema que aborda: El artículo aborda el problema que presentan algunos sistemas de bases de datos que utilizan aprendizaje automático cuando cambia la forma en que se realizan las consultas. Un modelo puede funcionar correctamente con los datos y consultas utilizados durante su entrenamiento, pero perder precisión cuando recibe información diferente o cuando cambia la carga de trabajo.

Esto es importante porque las consultas que realizan los usuarios no siempre son las mismas y pueden cambiar con el tiempo. Por ello, el sistema necesita una forma de adaptarse a estos cambios sin tener que comenzar nuevamente todo el proceso de aprendizaje.

Método o propuesta de los autores: Los autores proponen utilizar un replay buffer, que consiste en conservar una selección de ejemplos representativos de las cargas de trabajo que el sistema ha observado. Para administrar estos ejemplos utilizan algoritmos en línea, de manera que el contenido del replay buffer pueda actualizarse conforme aparecen nuevas consultas.

Con esta propuesta buscan que el modelo tenga información representativa tanto de las consultas anteriores como de los cambios que se presentan posteriormente. De esta manera, el sistema puede adaptarse a diferentes cargas de trabajo y mantener predicciones útiles para la optimización de consultas.

Resultado principal que reportan: A partir de sus experimentos, los autores muestran que el manejo del replay buffer permite mantener un conjunto de ejemplos pequeño, pero que representa de manera adecuada las diferentes cargas de trabajo.

Los resultados indican que este mecanismo ayuda a que los sistemas de bases de datos que utilizan aprendizaje automático se adapten a los cambios en las consultas. También permite realizar predicciones relacionadas con la cardinalidad y el costo de las consultas, aspectos importantes para que el sistema pueda elegir cómo ejecutar una consulta.

Relación con la Unidad Temática I

Tema de la Unidad Temática I: [Bases de datos, procesamiento y optimización de consultas](#).

Este artículo se relaciona con la Unidad Temática I principalmente por el tema de procesamiento y optimización de consultas. En una base de datos, el optimizador necesita realizar estimaciones para decidir cuál es una forma adecuada de ejecutar una consulta.

Lo interesante del artículo es que estas estimaciones pueden apoyarse en modelos de aprendizaje automático. Por lo tanto, el trabajo relaciona los conceptos básicos de las bases de datos con una aplicación actual de la inteligencia artificial, mostrando cómo estas tecnologías pueden utilizarse para mejorar el funcionamiento de un sistema de gestión de bases de datos.

¿Qué aporta a mi proyecto del curso?

Este artículo me aporta la idea de que una base de datos puede utilizar técnicas de aprendizaje automático no solamente para trabajar con la información almacenada, sino también para mejorar su propio funcionamiento.

En particular, me parece interesante la posibilidad de que el sistema pueda aprender de las consultas que recibe y adaptarse conforme cambia la manera en que los usuarios utilizan la base de datos. Esta idea podría aplicarse en mi proyecto para considerar mecanismos que permitan mejorar el rendimiento de las consultas a partir de la información obtenida durante el uso del sistema.

Wu, P., & Ives, Z. G. (2024). Modeling Shifting Workloads for Learned Database Systems. *Proceedings Of The ACM On Management Of Data*, 2(1), 1-27. <https://doi.org/10.1145/3639293>

Artículo: “[Stratus ML: A Layered Cloud Modeling Framework](#)” (Stratus ML: un marco de modelización de la nube por capas)

Autores: M. Hamdaqa and L. Tahvildari

DOI: <https://doi.org/10.14778/3407790.3407829>

Problema que aborda: Los autores abordan la falta de mediciones cuantitativas rigurosas sobre el impacto en el rendimiento de los entornos virtualizados, comparando la sobrecarga (overhead) que imponen las máquinas virtuales basadas en hipervisores frente a la virtualización ligera basada en contenedores al ejecutar tareas de procesamiento, memoria, almacenamiento de E/S y red.

Método o propuesta de los autores: Los investigadores diseñaron un entorno experimental controlado para ejecutar pruebas de rendimiento benchmarking (micro-benchmarks y macro-benchmarks) comparando hipervisores tradicionales (como KVM y Xen) contra motores de contenedores (Docker y LXC). Evaluaron métricas clave como tiempo de arranque del entorno, uso de memoria RAM, velocidad de transferencia de red y latencia de lectura/escritura en disco.

Resultado principal que reportan: Demuestran experimentalmente que los contenedores ofrecen tiempos de arranque prácticamente instantáneos (milisegundos) y un consumo de recursos significativamente menor respecto a las VMs. Adicionalmente, reportan que los contenedores logran un rendimiento de E/S (I/O) y red casi idéntico al del hardware nativo (bare-metal), mientras que las máquinas virtuales sufren una penalización de rendimiento medible por la capa de emulación del hipervisor y el sistema operativo huésped.

Relación con la Unidad Temática I

Se relaciona de forma explícita con el tema "[Virtualización vs. Contenedores](#):

Análisis Arquitectónico de Arranque, Consumo de Recursos (Tamaño) y Mecanismos de Aislamiento" de la Unidad Temática I.

¿Qué le aporta a su poryecyo?: Aporta respaldo científico y experimental para justificar el uso de contenedores en el despliegue de los servicios del proyecto. Permite argumentar con métricas reales por qué la baja latencia de E/S y el menor consumo de memoria de un contenedor optimizan el rendimiento en comparación con el despliegue sobre máquinas virtuales tradicionales.