

EJERCICIO 3. INVESTIGACIÓN: ¿QUÉ ES UNA BASE DE DATOS?

Unidad Temática I

Introducción

Las bases de datos constituyen una de las infraestructuras fundamentales de los sistemas informáticos actuales. Aplicaciones bancarias, plataformas educativas, comercio electrónico, redes sociales, sistemas de inventario y herramientas de inteligencia artificial dependen de mecanismos capaces de almacenar, organizar, proteger y recuperar datos de manera eficiente. Por ello, estudiar una base de datos no consiste únicamente en aprender a guardar registros, sino en comprender los modelos que permiten representar la realidad, las tecnologías que administran la información y los criterios para seleccionar un sistema de gestión adecuado.

Esta investigación revisa los conceptos de dato, información y base de datos; explica la transición del enfoque de archivos hacia los sistemas gestores de bases de datos (SGBD); describe la arquitectura ANSI-SPARC y la independencia de datos; compara distintos tipos de bases de datos y formas de clasificar los SGBD; y finalmente analiza la relación entre las bases de datos y los flujos de trabajo de inteligencia artificial. El objetivo es mostrar que la elección de una tecnología de datos depende del tipo de información, las consultas requeridas, el volumen, el número de usuarios, la distribución y las condiciones de operación.

1. Dato, información y base de datos

El dato puede entenderse como una representación de un hecho, una característica o una observación que puede ser registrada y procesada. Elmasri y Navathe (2016) definen los datos como hechos conocidos que pueden registrarse y que tienen un significado implícito. Desde esta perspectiva, un nombre, una fecha, una dirección o una medición son datos cuando representan algún aspecto de un contexto real.

La información aparece cuando los datos son organizados o procesados de forma que adquieren significado para una persona o una actividad. Connolly y Begg (2015) explican que la transformación y representación estructurada de los datos permite convertirlos en información útil para comprender una situación y apoyar decisiones. Por ejemplo, una lista de calificaciones es un conjunto de datos; calcular el promedio del grupo, identificar el porcentaje de aprobación y compararlo con otro periodo produce información.

En cuanto a la base de datos, Elmasri y Navathe (2016) la describen como una colección de datos relacionados, mientras que Connolly y Begg (2015) destacan que se trata de una colección compartida de datos relacionados lógicamente, junto con una descripción de esos datos, diseñada para satisfacer las necesidades de información de una organización. La primera definición pone énfasis en la relación y el significado de los datos; la segunda incorpora explícitamente el carácter compartido, el metadato y el propósito organizacional.

Estas definiciones son complementarias. Una base de datos no es simplemente una carpeta con archivos: existe una estructura que describe los datos, relaciones o reglas que permiten interpretarlos y mecanismos que facilitan su uso por diferentes aplicaciones y usuarios. IBM

(2024) señala que un sistema de base de datos incluye tanto el almacenamiento de los datos como el sistema de gestión que permite interactuar con ellos.

2. Fundamentos de las bases de datos

Antes de generalizarse los SGBD, muchas organizaciones administraban información mediante archivos independientes asociados a programas concretos. Este enfoque podía funcionar para aplicaciones pequeñas, pero generaba problemas al crecer el número de programas y usuarios. Entre las dificultades se encontraban la duplicación de datos, el aislamiento entre archivos, la dependencia entre los programas y la estructura física de los archivos, la incompatibilidad de formatos y la dificultad para establecer controles uniformes de seguridad y acceso (Connolly & Begg, 2015).

La duplicación podía provocar inconsistencias. Por ejemplo, si la dirección de un cliente estaba almacenada en varios archivos y se actualizaba solo en uno, el sistema podía terminar con diferentes versiones del mismo dato. Además, cada programa debía conocer la organización del archivo que utilizaba. Un cambio en esa organización podía obligar a modificar programas que dependían de ella. El enfoque de bases de datos surgió para colocar los datos como un recurso compartido y administrado centralmente, reduciendo estos problemas.

Un sistema gestor de bases de datos (SGBD o DBMS, por sus siglas en inglés) es el software que permite definir, crear, mantener y controlar el acceso a una base de datos. Entre sus funciones se encuentran la definición de estructuras, consulta y modificación de datos, administración de usuarios, control de concurrencia, recuperación ante fallos, seguridad y mantenimiento de metadatos (IBM, 2024).

En términos prácticos, el gestor actúa como intermediario entre las aplicaciones y los datos. Una aplicación solicita una operación, el SGBD interpreta la solicitud y determina cómo ejecutarla de acuerdo con el modelo de datos, las restricciones, los permisos y las estructuras de almacenamiento. Esta separación permite que los programas dependan menos de los detalles físicos de almacenamiento y facilita la administración de un recurso común.

3. Arquitectura ANSI-SPARC

La arquitectura ANSI-SPARC surgió de los trabajos del Standards Planning and Requirements Committee (SPARC) de ANSI sobre la estandarización de los sistemas de bases de datos. Un informe del National Bureau of Standards (1985) recuerda que el primer informe ANSI/SPARC introdujo un marco de tres esquemas: interno, conceptual y externo. El propósito general de esta separación era proporcionar una descripción organizada del sistema y favorecer la independencia entre las formas en que los usuarios observan los datos y la manera en que estos se almacenan.

El nivel externo representa las vistas de usuarios o aplicaciones. Puede haber varias vistas externas, cada una adaptada a una necesidad concreta. Por ejemplo, un sistema universitario puede presentar a un estudiante únicamente sus materias y calificaciones, mientras que una vista administrativa puede incluir información de inscripción y pagos. El esquema externo, por tanto, permite mostrar solo la información necesaria para cada grupo.

El nivel conceptual representa la estructura lógica global de la base de datos. Describe entidades, propiedades, relaciones y restricciones sin entrar en los detalles de almacenamiento físico. En esta capa se busca mantener una representación relativamente estable de la organización de los datos (National Bureau of Standards, 1985). Esta preocupación por representar conceptualmente el significado de los datos también se relaciona con el modelo entidad-relación propuesto por Chen (1976).

El nivel interno describe cómo se representan y almacenan los datos físicamente. Incluye estructuras de almacenamiento, métodos de acceso e índices. El usuario normalmente no necesita conocer estos detalles para realizar una consulta. La separación entre los niveles externo, conceptual e interno es una de las bases conceptuales de la independencia de datos.

4. Independencia de datos, lenguajes y módulos de un SGBD

La independencia de datos es la capacidad de modificar un nivel de descripción de una base de datos sin obligar a cambiar los niveles superiores que no dependen de ese detalle. El objetivo es disminuir el impacto que tienen los cambios en el almacenamiento o en la estructura lógica sobre las aplicaciones.

La independencia física permite cambiar aspectos del almacenamiento interno sin modificar el esquema conceptual ni las aplicaciones. Un ejemplo sería agregar un índice para acelerar una consulta, cambiar la organización de los archivos o migrar el almacenamiento a otro medio, manteniendo la misma estructura lógica para las aplicaciones.

La independencia lógica se refiere a la posibilidad de modificar la estructura conceptual sin tener que modificar todas las vistas externas o los programas que no se vean afectados. Por ejemplo, una organización podría incorporar un nuevo atributo a una entidad o reorganizar ciertas relaciones y mantener las vistas de los usuarios que solo utilizan los elementos anteriores. La independencia lógica suele ser más difícil de conseguir que la física porque los cambios conceptuales pueden alterar las consultas y las dependencias de las aplicaciones (Elmasri & Navathe, 2016).

Los SGBD también requieren lenguajes e interfaces para definir y manipular los datos. En los sistemas relacionales, SQL es el lenguaje más extendido y permite realizar operaciones de definición, consulta, inserción, actualización, eliminación y control de acceso. IBM (2024) señala que SQL se utiliza para tareas como definición de datos, acceso, control y consultas analíticas. En otros modelos existen lenguajes o APIs específicas, como los mecanismos de consulta de bases documentales o de grafos.

Entre los módulos habituales de un SGBD se encuentran el procesador de consultas, que analiza y optimiza las solicitudes; el gestor de almacenamiento, que organiza el acceso a los datos; el administrador de transacciones y control de concurrencia; los mecanismos de recuperación ante fallos; los componentes de seguridad y autorización; y el catálogo o diccionario de datos, que contiene metadatos sobre la estructura del sistema.

5. Tipos de bases de datos

No existe un único modelo adecuado para todos los problemas. Las bases de datos se especializan en diferentes formas de representar y consultar la información. AWS (2026)

identifica entre los modelos NoSQL comunes los de clave-valor, documentos, columnas y grafos, mientras que otras tecnologías están diseñadas específicamente para datos temporales, espaciales o vectoriales.

5.1 Relacionales

Las bases de datos relacionales organizan la información en relaciones que normalmente se representan mediante tablas de filas y columnas. Utilizan esquemas definidos, claves, restricciones y operaciones que permiten relacionar tablas. Son apropiadas cuando existen relaciones estructuradas y se necesitan transacciones y consultas complejas. Caso de uso real: un banco puede utilizar una base relacional para administrar clientes, cuentas, movimientos y transferencias, donde la integridad de las relaciones y las transacciones es fundamental. El trabajo de Codd (1979) es relevante para esta evolución porque explora extensiones del modelo relacional orientadas a representar más significado en los datos.

5.2 Documentales

Las bases documentales almacenan registros como documentos, habitualmente con estructuras semejantes a JSON. Su esquema flexible facilita representar objetos con atributos diferentes y estructuras jerárquicas. MongoDB (2026) documenta este modelo mediante documentos BSON organizados en colecciones. Caso de uso real: un comercio electrónico puede guardar catálogos de productos donde cada producto tiene atributos diferentes, además de reseñas y características anidadas.

5.3 De clave-valor

En un almacén clave-valor, cada elemento se identifica mediante una clave única asociada con un valor. Este modelo es sencillo y puede escalar horizontalmente, por lo que resulta útil cuando el patrón principal consiste en localizar rápidamente un elemento mediante su identificador (AWS, 2026). Caso de uso real: una aplicación web puede almacenar sesiones de usuarios usando el identificador de sesión como clave. Otros usos comunes incluyen carritos de compra y cachés de información.

5.4 Familias de columnas

Las bases de datos de familias de columnas, también llamadas wide-column, organizan grandes volúmenes de información mediante claves de fila y grupos de columnas que pueden variar según el registro. Están orientadas a escalabilidad y alto rendimiento en cargas distribuidas. Google Cloud (2026) describe Bigtable como un almacén de clave-valor y columnas anchas, apropiado para cargas de baja latencia, clics e IoT. Caso de uso real: una plataforma que recibe eventos de sensores o clics de millones de usuarios puede utilizar este modelo para ingerir y consultar grandes cantidades de datos.

5.5 De grafos

Las bases de grafos representan entidades como nodos y sus relaciones como aristas. AWS (2026) destaca que este modelo está diseñado para conjuntos altamente conectados. Caso de uso real: una institución financiera puede analizar relaciones entre cuentas, personas, dispositivos y transacciones para identificar patrones relacionados con fraude. También son utilizadas en redes sociales, recomendaciones y grafos de conocimiento.

5.6 Especializadas

Las bases especializadas se diseñan alrededor de una característica concreta de los datos o de las consultas. Tres ejemplos importantes son las bases de series de tiempo, espaciales y vectoriales.

Las bases de series de tiempo almacenan datos asociados a marcas temporales, como temperaturas, precios, métricas de servidores o telemetría. InfluxData (2026) señala que estos sistemas están optimizados para grandes volúmenes de datos con marcas de tiempo y consultas por intervalos. Caso de uso real: una empresa puede registrar métricas de servidores para generar paneles de monitoreo y alertas.

Las bases espaciales almacenan y procesan objetos geográficos, como puntos, líneas y polígonos. PostGIS documenta el uso de tipos espaciales, índices y funciones para consultar relaciones geográficas (PostGIS, 2026). Caso de uso real: una aplicación de mapas puede almacenar calles, zonas y ubicaciones para calcular distancias, intersecciones o rutas.

Las bases vectoriales almacenan representaciones numéricas llamadas embeddings, que permiten buscar elementos por similitud semántica. Google Cloud (2026) explica que la búsqueda vectorial utiliza índices de vectores para localizar vecinos cercanos y habilitar búsqueda semántica, recomendación y aplicaciones de IA generativa. Caso de uso real: un asistente empresarial puede convertir documentos internos en embeddings y recuperar los fragmentos más similares a una pregunta del usuario.

6. Clasificación de los sistemas gestores

Los SGBD pueden clasificarse de acuerdo con distintos criterios, y una misma tecnología puede pertenecer simultáneamente a varias categorías.

- Por propósito: pueden distinguirse sistemas de propósito general, orientados a una amplia variedad de aplicaciones, y sistemas especializados, diseñados para necesidades concretas como series de tiempo, datos espaciales o búsqueda vectorial.
- Por modelo de datos: pueden clasificarse en relacionales, documentales, clave-valor, familias de columnas, grafos y otros modelos. Algunos productos actuales son multimodelo y combinan más de una forma de representación.
- Por número de usuarios: pueden ser monousuario, cuando el acceso concurrente es limitado o no constituye el objetivo principal, o multiusuario, cuando están diseñados para atender a numerosos usuarios y procesos simultáneamente.
- Por número de sitios: un sistema puede ser centralizado cuando los datos se administran principalmente en un solo sitio; distribuido cuando los datos o componentes se encuentran en varios nodos o ubicaciones; y también existen configuraciones replicadas y federadas.
- Por licencia: existen soluciones propietarias o comerciales, cuyo uso está regulado por contratos y licencias del proveedor; soluciones de código abierto, cuyo código y condiciones de uso se encuentran bajo licencias específicas; y modelos mixtos en los que diferentes componentes tienen distintas condiciones.

Estos criterios deben analizarse en conjunto. Por ejemplo, un SGBD puede ser NoSQL, distribuido, multiusuario, especializado en documentos y estar disponible bajo un modelo de

licencia de código abierto o comercial. La clasificación ayuda a describir la tecnología, pero no sustituye el análisis de los requisitos de una aplicación.

7. Bases de datos en flujos de trabajo de inteligencia artificial

La inteligencia artificial depende de datos en varias etapas: recopilación, limpieza, etiquetado, transformación, entrenamiento, evaluación, inferencia y recuperación de información. En este contexto, las bases de datos funcionan como infraestructura para conservar datos, metadatos y características que deben ser reutilizados de forma controlada.

En el almacenamiento de conjuntos de entrenamiento, un sistema de datos permite conservar ejemplos, etiquetas, metadatos y versiones. Los feature stores son un ejemplo específico: AWS (2026) describe estos repositorios como capas para almacenar, compartir, administrar y recuperar características utilizadas durante entrenamiento e inferencia. Además, se pueden mantener almacenes offline para entrenamiento y almacenes online para consultas de baja latencia durante la inferencia. La consistencia temporal es importante porque usar información que no estaba disponible en el momento de una predicción puede introducir fuga de información y producir evaluaciones engañosas.

Las bases de datos también participan en la recuperación de información. En un sistema de recuperación aumentada por generación (RAG), el modelo no depende únicamente de la información almacenada en sus parámetros. Lewis et al. (2020) presentaron un enfoque en el que un modelo generativo consulta una memoria externa no paramétrica mediante un índice denso de vectores. Esto permite recuperar fragmentos relevantes y utilizarlos como contexto para producir una respuesta.

La búsqueda por similitud es especialmente importante cuando la consulta y el contenido no comparten exactamente las mismas palabras. Un modelo puede transformar un texto, imagen u otro objeto en un vector que representa ciertas características semánticas. Una base vectorial puede entonces localizar otros vectores cercanos según una medida de similitud. Google Cloud (2026) señala que este mecanismo puede utilizarse en búsqueda semántica, recomendaciones y aplicaciones generativas.

Por ello, un flujo moderno de IA puede combinar varias tecnologías: almacenamiento de archivos para datos originales, bases relacionales o documentales para metadatos y registros, un feature store para características de aprendizaje automático y un índice vectorial para recuperación semántica. La base de datos no reemplaza al modelo de IA; proporciona la infraestructura que permite que los datos necesarios sean almacenados, gobernados, recuperados y utilizados de manera reproducible.

Conclusión

Una base de datos puede entenderse como un recurso organizado de datos relacionados, acompañado por estructuras y metadatos que permiten utilizarlo de manera consistente. La evolución desde el enfoque de archivos hacia los SGBD respondió a problemas de duplicación, aislamiento, dependencia de los programas, seguridad y dificultad de administración. La arquitectura ANSI-SPARC aportó una forma de separar las vistas externas, la estructura

conceptual y el almacenamiento interno, dando fundamento al concepto de independencia de datos.

La diversidad de aplicaciones ha producido distintos modelos: relacional para datos estructurados y transacciones, documental para información flexible, clave-valor para accesos directos, familias de columnas para grandes cargas distribuidas, grafos para relaciones complejas y modelos especializados para tiempo, espacio y similitud vectorial. Finalmente, la expansión de la inteligencia artificial ha incrementado la importancia de los sistemas capaces de administrar conjuntos de entrenamiento, características y grandes colecciones de documentos y embeddings. En consecuencia, comprender las bases de datos significa comprender una parte esencial de la infraestructura que sostiene tanto los sistemas de información tradicionales como las aplicaciones modernas de IA.

Referencias

Amazon Web Services. (2026). Choosing an AWS NoSQL database: Types of NoSQL

databases. AWS Documentation.

Amazon Web Services. (2026). Amazon SageMaker Feature Store. AWS.

Connolly, T. M., & Begg, C. E. (2015). Database systems: A practical approach to design, implementation, and management (6th ed.). Pearson.

Elmasri, R., & Navathe, S. B. (2016). Fundamentals of database systems (7th ed.). Pearson.

Google Cloud. (2026). Bigtable: Fast, flexible NoSQL. Google Cloud.

Google Cloud. (2026). Vector Search. Vertex AI Documentation.

IBM. (2024). What is a database? IBM Think.

InfluxData. (2026). Frequently asked questions: Time series data and InfluxDB. InfluxData Documentation.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. arXiv. <https://doi.org/10.48550/arXiv.2005.11401>

MongoDB. (2026). Database and collection concepts. MongoDB Documentation.

National Bureau of Standards. (1985). Reference model for DBMS standardization (NBSIR 85-3173). U.S. Department of Commerce.

PostGIS. (2026). Introduction to PostGIS. PostGIS Documentation.

Silberschatz, A., Korth, H. F., & Sudarshan, S. (2020). Database system concepts (7th ed.). McGraw-Hill.

Chen, P. P.-S. (1976). The entity-relationship model—Toward a unified view of data. ACM Transactions on Database Systems, 1(1), 9–36. <https://doi.org/10.1145/320434.320440>

Codd, E. F. (1979). Extending the database relational model to capture more meaning. ACM Transactions on Database Systems, 4(4), 397–434. <https://doi.org/10.1145/320107.320109>